Yangın ve Duman Tespiti

Model değerlendirmesi, hız analizi, sunucu gereksinimleri ve dağıtım seçenekleri

Staj prototip projesi · 25 Ekim 2026 · Modeller: YOLO11s, YOLOv8s, RT-DETR-l · Ölçüm donanımı: NVIDIA A100 (Google Colab Pro)

1 Yönetici özeti
2 Proje ve test düzeni
3 Doğruluk sonuçları ve metrikler
4 Hız: bir görüntü kaç ms sürüyor?
5 Bir sunucu kaç kamerayı kaldırır?
6 Sunucu gereksinimleri
7 Dağıtım seçenekleri ve maliyet
8 Modeli hedef donanıma taşıma
9 Öneri ve sonraki adımlar
10 Varsayımlar ve kaynaklar

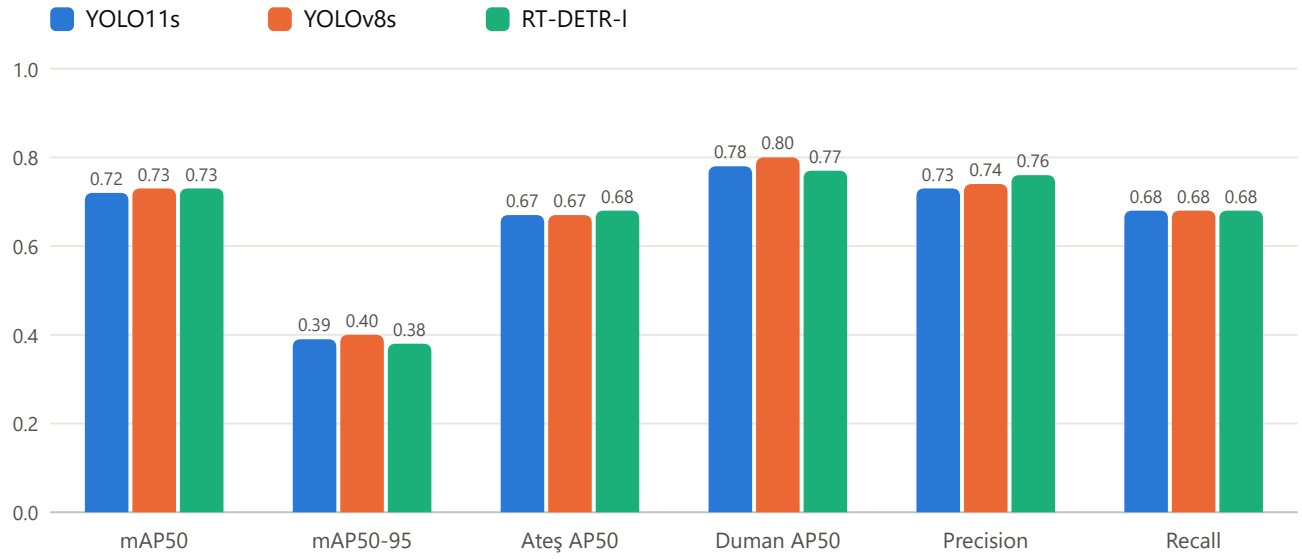
1 Yönetici özeti

- **Doğrulukta belirgin bir kazanan yok.** Üç model de test setinde mAP50 ≈ 0.72-0.73 ve Recall ≈ 0.68 sonucuna ulaştı. En yüksek mAP50-95 YOLOv8s'te (0.40), en yüksek Precision RT-DETR-l'de (0.76).
- **Hızda fark büyük.** A100 GPU'da bir görüntü YOLOv8s ile ~12 ms, YOLO11s ile ~13 ms, RT-DETR-l ile ~66 ms sürüyor. Saniyede sırasıyla ~83, ~77 ve ~15 görüntü işleniyor. RT-DETR ~5 kat yavaş.
- **Yangın tespiti saniyede 25-30 kare gerektirmiyor.** Kamera başına saniyede 1-2 kare yeterli. Alarm süresini model değil, yanlış alarmı önleyen doğrulama penceresi belirliyor (uçtan uca ~3-5 sn).
- **Önerilen mimari: hibrit.** Binada bir gömülü cihaz (Jetson Orin Nano Super) YOLOv8s/YOLO11s ile tespit yapar. Bulutta küçük bir sunucu bildirim, panel ve RT-DETR ile ikinci kontrol işlerini üstlenir. 16 kameralık bir bina için 12 aylık maliyet **≈ $470**. Tamamen bulut çözümünde bu tutar **≈ $2.900-4.600**.

2 Proje ve test düzeni

Konu	Değer
Problem	Nesne tespiti (object detection), 2 sınıf: **ateş** (fire), **duman** (smoke)
Veri seti	D-Fire (Kaggle: `sayedgamal99/smoke-fire-detection-yolo`), ~21 bin görsel, CC0 lisanslı. Alt küme kullanıldı: 4.000 train (+~1.200 augmented), 800 val, 800 test
Ön işleme	Etiket temizliği, tabakalı örnekleme (%15 arka plan görseli), split'ler arası kopya eleme, uzun kenarı 640 piksele küçültme
Augmentation	Online: mosaic, mixup, HSV, yatay çevirme, ölçek, döndürme, perspektif. Offline: bulanıklık, sensör gürültüsü, JPEG sıkıştırma, gece, IR (gri), sis, açılı kamera
Modeller	YOLO11s, YOLOv8s, RT-DETR-l. Hepsi COCO ön-eğitimli ağırlıklardan fine-tune edildi. Aynı veri, 640×640 girdi, aynı augmentation ayarları
Test	Eğitimde hiç görülmeyen 800 görsellik test seti
Hız ölçümü	NVIDIA A100, PyTorch, batch = 1, optimizasyonsuz. Ön işleme + çıkarım + son işleme süresi; 100 görselin ortalaması

3 Doğruluk sonuçları ve metrikler



Şekil 1 - Test seti doğruluk metrikleri (yüksek = iyi). Değerler değerlendirme grafiğinden iki ondalık hassasiyetle okunmuştur. Kesin değerler `outputs/reports/model_comparison.md` dosyasındadır.

Model	mAP50	mAP50-95	Ateş AP50	Duman AP50	Precision	Recall
YOLO11s	0.72	0.39	0.67	0.78	0.73	0.68
YOLOv8s	**0.73**	**0.40**	0.67	**0.80**	0.74	0.68
RT-DETR-l	**0.73**	0.38	**0.68**	0.77	**0.76**	0.68

Metrikler ne anlama geliyor?

IoU (Intersection over Union): Modelin çizdiği kutu ile insanın çizdiği doğru kutunun örtüşme oranıdır. İki kutunun kesişim alanı birleşim alanına bölünür. 1.0 birebir eşleşme, 0.5 yarı yarıya örtüşme demektir. Bir tespitin "doğru" sayılması için IoU'nun belirli bir eşiği geçmesi gerekir.

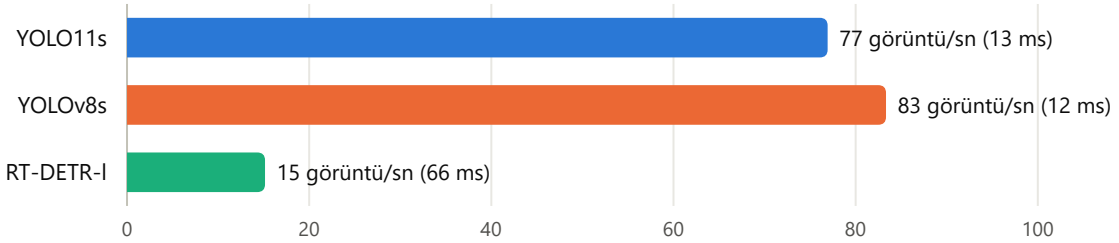
Metrik	Sorduğu soru	Yorum
Precision	Model "ateş" dediğinde ne kadar haklı?	Düşükse sistem çok yanlış alarm verir (örneğin gün batımına "yangın" der).
Recall	Gerçek ateş ve dumanların ne kadarı yakalandı?	Düşükse yangınlar kaçırılır. Yangın sisteminde **en kritik metrik**.
AP	Tüm güven eşikleri denendiğinde precision-recall dengesi ne kadar iyi?	Eşik seçiminden bağımsız olduğu için modelleri karşılaştırmanın standart yolu.
Ateş / Duman AP50	Tek bir sınıf için AP, IoU ≥ 0.5 iken	Sınıf bazında başarı. Duman (~0.78) ateşten (~0.67) daha iyi tespit ediliyor.
mAP50	İki sınıfın AP50 ortalaması ("m" = mean)	"Kutu yaklaşık doğru yerde mi?" Alarm sistemi için en anlamlı özet metrik.
mAP50-95	IoU 0.50, 0.55 … 0.95 eşiklerinde ölçülen mAP'lerin ortalaması	"Kutu sınırlara ne kadar sıkı oturuyor?" sorusunu ölçer, daha katıdır.

mAP50-95 neden düşük (~0.39)? Dumanın net bir sınırı yoktur; iki insan bile aynı duman bulutuna farklı kutu çizer. Bu yüzden yüksek IoU eşiklerinde puan düşer. Yangın ve duman veri setlerinde bu normaldir.

Recall 0.68 ne demek? Hesap görsel bazında değil kutu bazında yapılır. Bir görselde 3 duman bulutu varsa ve model 2'sini bulursa, o görselde alarm yine verilir, ama recall'a 2/3 olarak yansır. Görsel bazında yakalama oranı bu sayıdan daha yüksektir. Precision ve recall değerleri Ultralytics'in seçtiği en dengeli güven eşiğinde hesaplanmıştır; demoda kullanılan 0.35 eşiğinde biraz farklı olabilir.

4 Hız: bir görüntü kaç ms sürüyor?

Formül: saniyede işlenen görüntü (FPS) = 1000 / görüntü başına gecikme (ms)



Şekil 2 - A100 GPU'da, PyTorch ile, görüntüler tek tek işlenirken (batch = 1) saniyede işlenen görüntü sayısı. Birim: görüntü/sn. Uzun çubuk = daha hızlı.

Model	Bir görüntünün işlenme süresi	Saniyede görüntü	YOLOv8s'e göre
YOLOv8s	~12 ms (0.012 sn)	~83	1.0×
YOLO11s	~13 ms (0.013 sn)	~77	1.1× daha yavaş
RT-DETR-l	~66 ms (0.066 sn)	~15	5.5× daha yavaş

> **A100 ile ilgili önemli not:** A100 en üst seviye veri merkezi GPU'larından biridir. Sahada kullanılacak donanım (T4, Jetson vb.) daha zayıf olacağı için bu süreler **iyimser** kabul edilmelidir. Batch = 1 ile çalışırken sürenin önemli kısmı Python, ön işleme ve son işleme yükünden gelir. Bu yüzden daha zayıf bir GPU'da süre doğrusal artmaz, ama T4'te PyTorch ile **~1.5-2 kat** daha yavaş olması beklenir. Ölçüm video çözme, ağ gecikmesi ve görüntüyü diskten okuma süresini içermez.

Gerçek sistemde uçtan uca süre

Kameradan alarma kadar geçen süre (YOLOv8s, kamera başına saniyede 2 kare):

Adım	Süre
Sıradaki karenin gelmesini bekleme (saniyede 2 kare → en fazla)	500 ms
H.264 videoyu çözme (720p ikinci akış)	~5 ms
Model işlemi: ön işleme + çıkarım + son işleme (A100 ölçümü)	~12 ms
Alan hesabı ve alarm mantığı	~1 ms
Tek bir karenin işlenmesi	**~20 ms**
Yanlış alarmı önlemek için doğrulama (örn. son 5 karenin 3'ünde ateş)	~1.5-2.5 sn
Bildirimin gönderilmesi (Telegram / SMS)	~1-2 sn
Yangının görüntüye girmesinden alarma kadar	**~3-5 sn**

> **Sonuç:** Model işlemi toplam sürenin %1'inden azdır; darboğaz model değil, doğrulama penceresidir. Ateş ve duman saniyeler içinde geliştiği için **kamera başına saniyede 1-2 kare yeterlidir**. Saniyede 25 kare yerine 2 kare işlemek, aynı donanımla **~12 kat daha fazla kamera** izlenebilmesi demektir.

5 Bir sunucu kaç kamerayı kaldırır?

Formül: kamera sayısı = FPS × 0.7 / kamera başına kare hızı. Kamera başına saniyede 2 kare varsayıldı; sunucunun %100 dolu çalışmaması için kapasitenin %70'i kullanılabilir sayıldı.

Model	A100, PyTorch (ölçülen)	T4, PyTorch (tahmin)	T4, TensorRT FP16 (tahmin)
YOLOv8s	83 FPS → ~30 kamera	~45 FPS → ~15 kamera	~150 FPS → ~50 kamera
YOLO11s	77 FPS → ~27 kamera	~42 FPS → ~14 kamera	~140 FPS → ~50 kamera
RT-DETR-l	15 FPS → ~5 kamera	~8 FPS → ~3 kamera	~40 FPS → ~14 kamera

T4 sütunları tahmindir ve hedef donanımda `yolo benchmark` komutuyla ölçülmelidir. Tablodan çıkan iki sonuç var:

- **TensorRT'ye çevirmek kapasiteyi ~3 kat artırır.** Gerçek dağıtımda model PyTorch ile değil TensorRT ile çalıştırılmalıdır.
- **RT-DETR ana tespit modeli olarak uygun değil.** Doğruluğu YOLO modelleriyle neredeyse aynıyken ~3-5 kat daha az kamera izleyebiliyor. Ana tespit için YOLOv8s veya YOLO11s kullanılmalı.

6 Sunucu gereksinimleri

~30-50 kamera izleyecek merkezi bir sunucu için:

Bileşen	Gereksinim	Gerekçe
GPU	NVIDIA, 16 GB (T4, L4, RTX 4000 Ada sınıfı)	Model çalıştırma. 8 GB tek model için yeter; 16 GB ileride birden fazla model çalıştırmaya yer bırakır.
CPU	8 çekirdek	Video çözme işlemci açısından ağırdır. GPU'nun video çözücüsü (NVDEC) kullanılırsa yük azalır.
RAM	16-32 GB	Kamera akışlarının tamponları ve servisler.
Disk	200 GB+ SSD	Alarm anlarındaki klipler ve fotoğraflar. Sürekli kayıt kameraların kayıt cihazında (NVR) kalır.
Ağ	Kamera başına ~1 Mbps gelen trafik	Kameranın düşük çözünürlüklü **ikinci akışı** (substream, 720p) kullanılmalı. Model zaten 640 piksele küçülttüğü için 1080p ana akış doğruluğu artırmaz, sadece bant genişliği harcar.

Yazılım katmanları

Katman	Araç
İşletim sistemi	Ubuntu 22.04 / 24.04, NVIDIA sürücüsü, Docker + NVIDIA Container Toolkit
Video alma	FFmpeg / GStreamer veya NVIDIA DeepStream (RTSP, NVDEC ile donanımsal çözme)
Model çalıştırma	TensorRT motoru. Çok sayıda kamera için Triton Inference Server
Uygulama servisi	Projedeki `predict.py` mantığı + zamansal doğrulama + alarm kuralları
Veritabanı	PostgreSQL (alarm kayıtları, kamera listesi)
Bildirim	Telegram, SMS veya e-posta
İzleme	**Kamera sağlık takibi:** bağlantısı kopan bir kamera o alanda yangını göremez, bu da ayrı bir alarm olarak bildirilmeli. GPU ve servis izleme.

> **Hukuki not (KVKK):** İnsan görüntüsü içeren kamera kayıtları kişisel veridir. Sunucu yurt dışındaysa (örneğin AWS Frankfurt veya Hetzner Almanya) yurt dışına veri aktarım kurallarına uyulmalı. Kayıtların saklama süresi belirlenmeli ve bina ile sunucu arasındaki bağlantı VPN ile şifrelenmeli.

7 Dağıtım seçenekleri ve maliyet

Örnek senaryo: 1 bina, 16 IP kamera, kamera başına saniyede 2 kare.

A) Tamamen bulut

Kameralar görüntüyü VPN üzerinden buluttaki GPU sunucusuna gönderir. Tespit ve alarm orada yapılır.

Seçenek	Aylık	12 ay
AWS g4dn.xlarge (T4 GPU), kullandıkça öde ($0.526/saat)	~$384	~$4.608
AWS g4dn.xlarge, 1 yıl taahhüt ($0.331/saat)	~$242	~$2.904
Hetzner GEX45 (Almanya, sabit fiyat, KDV hariç)	€214	€2.568 + kurulum

16 kamera için T4 sunucusunda **TensorRT kullanmak gerekir**: PyTorch ile kapasite ~15 kamera, yani sınırda.

Artı

- Tek merkezden yönetim
- Model güncellemesi kolay

Eksi

- Binanın sürekli ~16 Mbps **upload** hızı olmalı
- **İnternet kesilirse sistem kör kalır**
- Aylık maliyet yüksek, KVKK yükü büyük

B) Gömülü (edge): binadaki küçük bir cihaz

Kameraların yanına küçük bir yapay zekâ bilgisayarı konur. Tespit yerinde yapılır, dışarıya sadece alarm ve fotoğraf gönderilir.

Cihaz	Maliyet (tek seferlik)	Kapasite (tahmin)	Not
NVIDIA Jetson Orin Nano Super	Kit $249 (ABD çıkış fiyatı). SSD, kasa, adaptörle ~$350	~10-20 kamera	**Önerilen.** Ultralytics resmi olarak destekliyor, TensorRT ile çalışır, mevcut kod neredeyse aynen çalışır. Saniyede 1 kare ile kapasite iki katına çıkar.
Raspberry Pi 5 + AI HAT+ (Hailo-8, 26 TOPS)	~$80 + $110-132	~4-10 kamera	Ucuz. Ancak modeli Hailo'nun kendi formatına (HEF) çevirmek zahmetli. RT-DETR desteklenmiyor.
Intel işlemcili mini PC (OpenVINO)	~$300-500	~5-10 kamera	GPU gerektirmez.
Raspberry Pi 5 tek başına (CPU)	~$80	1-2 kamera	Sadece deneme amaçlı.

Kapasite değerleri tahmindir; satın almadan önce cihaz üzerinde ölçülmelidir. Türkiye'de ithalat ve vergiler nedeniyle fiyatlar belirgin şekilde daha yüksek olur. Cihaz ~15-25 W elektrik harcar (aylık ~15 kWh).

Artı

- İnternet kesilse de tespit sürer; yerel siren tetiklenebilir

Eksi

- Sahada bakım gerekir
- Uzaktan model güncellemesi (OTA) kurulmalı

- Bant genişliği neredeyse sıfır; görüntü binadan çıkmaz (KVKK açısından en temiz çözüm)
- Kendini 1-2 ayda amorti eder
- 16 kamera Orin Nano Super için sınırda; ölçüm şart

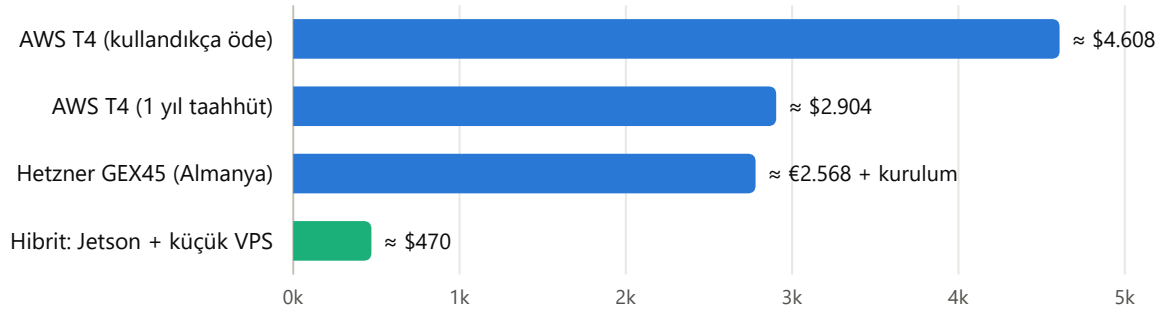
C) Hibrit (önerilen)

```
[IP kameralar] --RTSP--> [Jetson (binada)] --alarm + fotoğraf--> [Bulut sunucusu]
                         YOLOv8s / YOLO11s                      - RT-DETR ile ikinci kontrol
                         saniyede 2 kare                        - Telegram / SMS bildirimi
                         yerel siren / röle                     - panel + alarm geçmişi
                         (internet olmasa da çalışır)           - model güncellemeleri
```

RT-DETR'in rolü: Gerçek zamanlı tespit için yavaş, ama en yüksek precision (0.76) onda. Gömülü cihazdaki YOLO "ateş var" dediğinde alarm fotoğrafı buluttaki RT-DETR'e gönderilir; RT-DETR de onaylarsa bildirim gider. Bu yanlış alarmları azaltır. Günde yalnızca birkaç fotoğraf işleneceği için GPU'suz ucuz bir sunucu bile yeterlidir.

Kalem	Maliyet
Bina başına Jetson Orin Nano Super (SSD, kasa, adaptör dahil)	~$350, tek seferlik
Bulut sunucusu: panel + bildirim + RT-DETR kontrolü (GPU'suz VPS, tüm binalar için ortak)	~€5-20/ay

12 aylık maliyet karşılaştırması (16 kamera)



Şekil 3 - 12 aylık toplam maliyet (USD). Hibrit: $350 cihaz + 12 × ~$10 VPS. Hetzner çubuğu euro tutarının yaklaşık dolar karşılığıdır. Fiyatlara vergi, Türkiye ithalat masrafları ve işçilik dahil değildir.

8 Modeli hedef donanıma taşıma

Eğitilmiş `best.pt` dosyası tek komutla hedef donanımın formatına çevrilir:

Hedef	Komut
Bulut GPU / Jetson (TensorRT)	`yolo export model=best.pt format=engine half=True` Hedef cihazın üzerinde çalıştırılmalı.
Jetson, daha hızlı (INT8)	`yolo export model=best.pt format=engine int8=True data=data.yaml`
Intel CPU	`yolo export model=best.pt format=openvino`
Raspberry Pi (CPU)	`yolo export model=best.pt format=ncnn`
Hailo (AI HAT+)	ONNX'e çevrilir, ardından Hailo Dataflow Compiler ile HEF'e

Çevrilen dosyanın projedeki `predict.py --weights ...` komutuna doğrudan verilebilmesi beklenir; bu henüz test edilmedi.

Ürünleşme için gereken eklemeler

- **Kamera başına kare sınırlama:** Ultralytics'in `vid_stride` ayarıyla, örneğin 25 FPS'lik akışta her 12-13 karede bir kare işlemek.
- **Zamansal doğrulama:** "Son 5 karenin 3'ünde ateş varsa alarm" gibi bir kural.
- **Çoklu kamera:** Birden fazla RTSP akışını aynı anda işleme.
- **Bildirim ve kamera sağlık takibi.**

9 Öneri ve sonraki adımlar

1. **Ana model:** YOLOv8s. En yüksek mAP50-95 ve en hızlı model. YOLO11s ona çok yakın bir alternatif.
2. **Doğrulama modeli:** RT-DETR-l, sadece alarm fotoğraflarının buluttaki ikinci kontrolü için.
3. **Mimari:** Hibrit. Binada Jetson, bulutta küçük bir sunucu.
4. **Kısa vadeli işler:** Zamansal doğrulama ve `vid_stride` eklenmeli. TensorRT'ye çevrilen modelin hızı ölçülmeli. Recall'ı artırmak için güven eşiği ayarlanmalı ve tam veri setiyle (~21 bin görsel) eğitim yapılmalı.
5. **Satın almadan önce:** Bir Jetson Orin Nano Super üzerinde 16 kameralık yük gerçekten ölçülmeli.

10 Varsayımlar ve kaynaklar

- Doğruluk ve hız değerleri A100 GPU'da, PyTorch ile ölçülmüştür. Rapordaki doğruluk değerleri grafikten iki ondalık hassasiyetle okunmuştur.
- Turuncu ile işaretlenen T4, TensorRT ve gömülü cihaz değerleri tahmindir; hedef donanımda ölçülmelidir.
- Fiyatlar Ekim 2026 itibarıyla aşağıdaki kaynaklardan alınmıştır. AWS fiyatları üçüncü taraf bir fiyat takip sitesinden, Hetzner fiyatı bir karşılaştırma yazısındandır; bütçeleme öncesinde sağlayıcıların kendi sayfalarından doğrulanmalıdır. Vergi, ithalat masrafı ve işçilik dahil değildir. Hetzner'in eski GEX44 modeli (€184/ay) artık satılmamaktadır.

- Uçtan uca alarm süresindeki video çözme, doğrulama ve bildirim süreleri tipik değerlerdir.

AWS g4dn.xlarge fiyatı (Holori): https://calculator.holori.com/aws/ec2/g4dn.xlarge/us-east-1
Hetzner GPU sunucu karşılaştırması: https://wz-it.com/en/blog/hetzner-gpu-server-comparison/
Hetzner GPU sunucu duyurusu: https://www.hetzner.com/fr/pressroom/new-gpu-server/
Jetson Orin Nano Super, $249: https://hwbusters.com/news/nvidias-jetson-orin-nano-super-developer-kit-power-affordability-and-ai-innovation-at-249/
Ultralytics YOLO11 on Jetson Orin Nano Super: https://www.ultralytics.com/blog/ultralytics-yolo11-on-nvidia-jetson-orin-nano-super-fast-and-efficient
Raspberry Pi AI HAT+ (Tom's Hardware): https://www.tomshardware.com/raspberry-pi/raspberry-pi-release-higher-performance-ai-hat-13-and-26-tops-variants
SparkFun AI HAT+ 26 TOPS: https://www.sparkfun.com/raspberry-pi-ai-hat-26-tops.html
Raspberry Pi AI HAT+ rehberi: https://raspberry.tips/en/raspberrypi-tutorials/raspberry-pi-ai-hat-plus-ai-acceleration